JORNADAS DE INVESTIGADORES · INSTITUTO DE INVESTIGACIONES GINO GERMANI

Análisis comparativo de modelos **RoBERTa** y estrategias de **clasificación** para la medición **ordinal** de la **polarización afectiva** a partir del **modelo circunflejo del afecto**

Agustín Nielsen (IIGG-FSOC-UBA)

Estudiante avanzado Lic. en Sociología (FSOC-UBA)

EJE 9 · TEORÍAS, EPISTEMOLOGÍAS Y METODOLOGÍAS

PLN · ANÁLISIS DE SENTIMIENTO · REGRESIÓN ORDINAL

Planteo del problema y definiciones conceptuales [CASO: IMÁGENES CON IA DE JAVIER MILEI EN INSTAGRAM · OCT 2023 – DIC 2024]

¿Qué? Procesos de polarización afectiva

Definición: "Distancia en grados de las emociones de votantes de distintos partidos al observar un mensaje político", mediada por el aumento de la incivilidad en redes y la urgencia de interactuar validando o confrontando (Calvo & Aruguete, 2023, pp. 56–57).

Las reacciones afectivas surgen frente a la *representación* dada por las imágenes generadas con IA (entendidas como elemento condensador en su contexto sociopolítico).

¿Cómo? Clasificación automática · Análisis de sentimiento

Definición: "La tarea de clasificar sentimiento, la orientación positiva o negativa que un escritor expresa hacia un objeto" (Jurafsky & Martin, 2026, p. 92).

El sentimiento es bipolar y excluyente, y se da siempre *respecto a un otro* ante un estímulo: es el **producto de una relación social** y del posicionamiento de un actor frente a otro en los comentarios.

Afecto nuclear

Russell & Feldman Barrett (1999)

"El sentimiento más elemental accesible desde la consciencia" (p. 806). Puede o no estar referido a un objeto y varía a través del tiempo.

> **Placer / Displacer:** "qué tan bien le va a uno" (p. 809).

> **Activación / Desactivación:** "refiere a la sensación de movilización o energía" (p. 809).

Episodios emocionales prototípicos

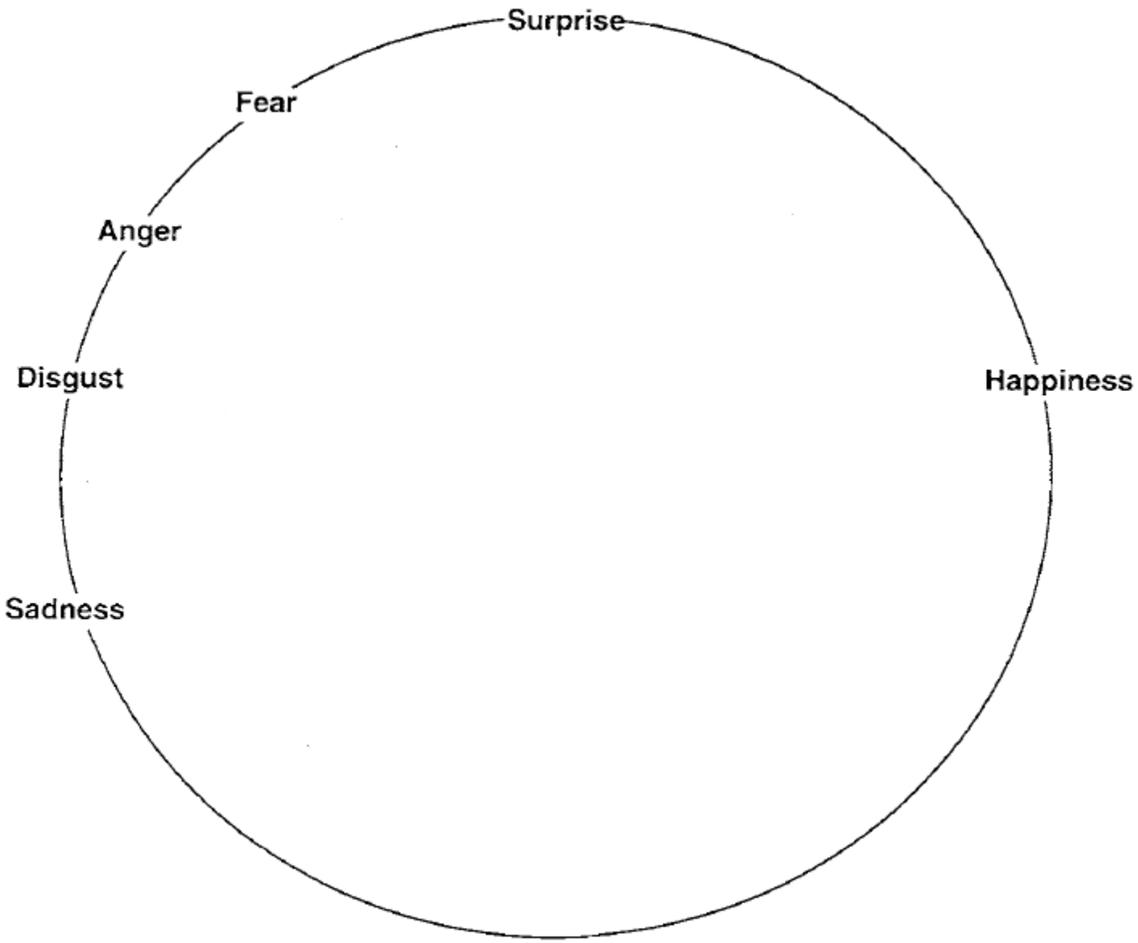
Russell & Feldman Barrett (1999)

- **Definición:** "Un grupo complejo de eventos interrelacionados referidos a un objeto específico" (p. 806) — *ej.: ira, euforia, miedo o asco*.
- Cualitativamente complejos de medir por fuera de casos ejemplares.
- Se manifiestan en períodos específicos con un principio y fin.
- Útiles desde la autocategorización, pero presentan dificultades para atribuirlos a los sujetos.

[ESQUEMA TEÓRICO · PASO 1 / 4]

Episodios emocionales prototípicos

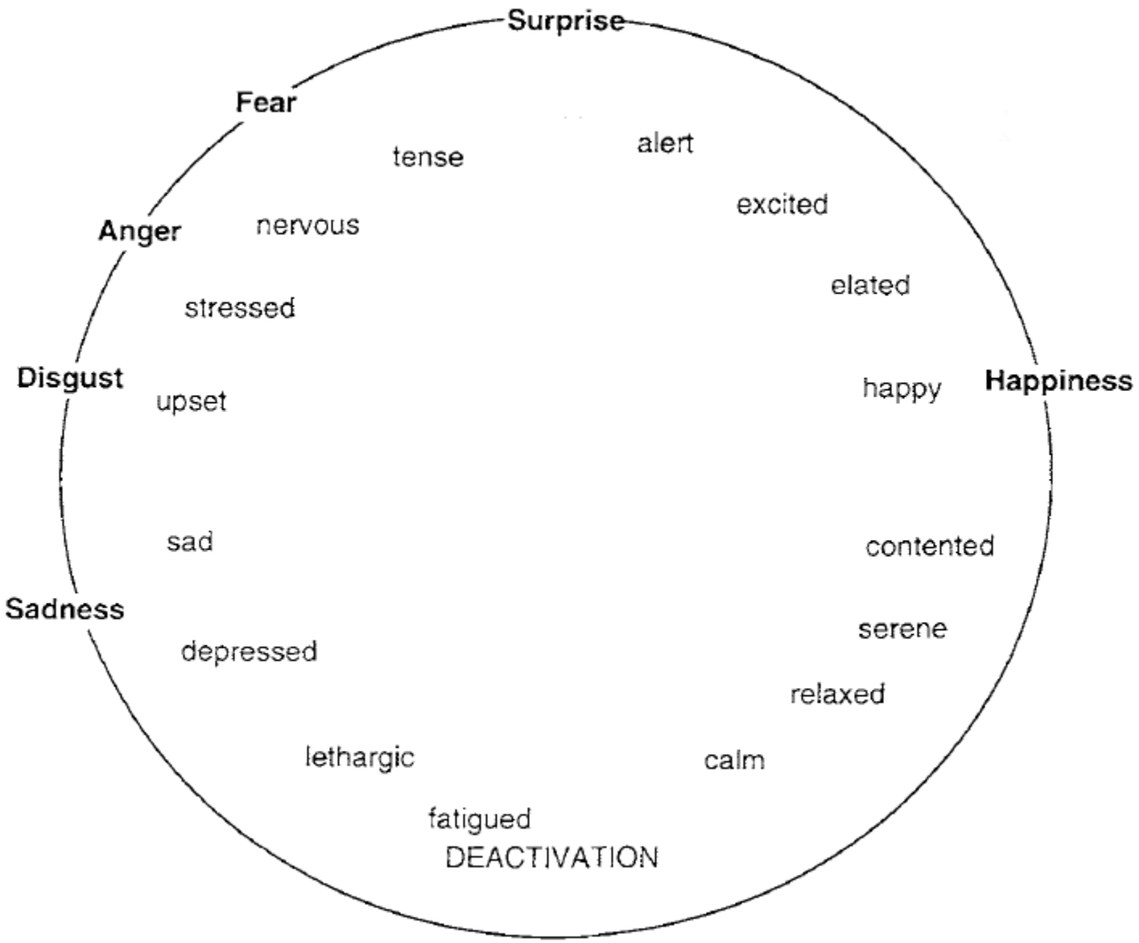
Las emociones discretas clásicas (*sorpresa, miedo, ira, asco, tristeza, felicidad*) se ubican como referencias prototípicas alrededor del perímetro, pero no agotan el espacio afectivo continuo.



[ESQUEMA TEÓRICO · PASO 2 / 4]

Episodios emocionales prototípicos

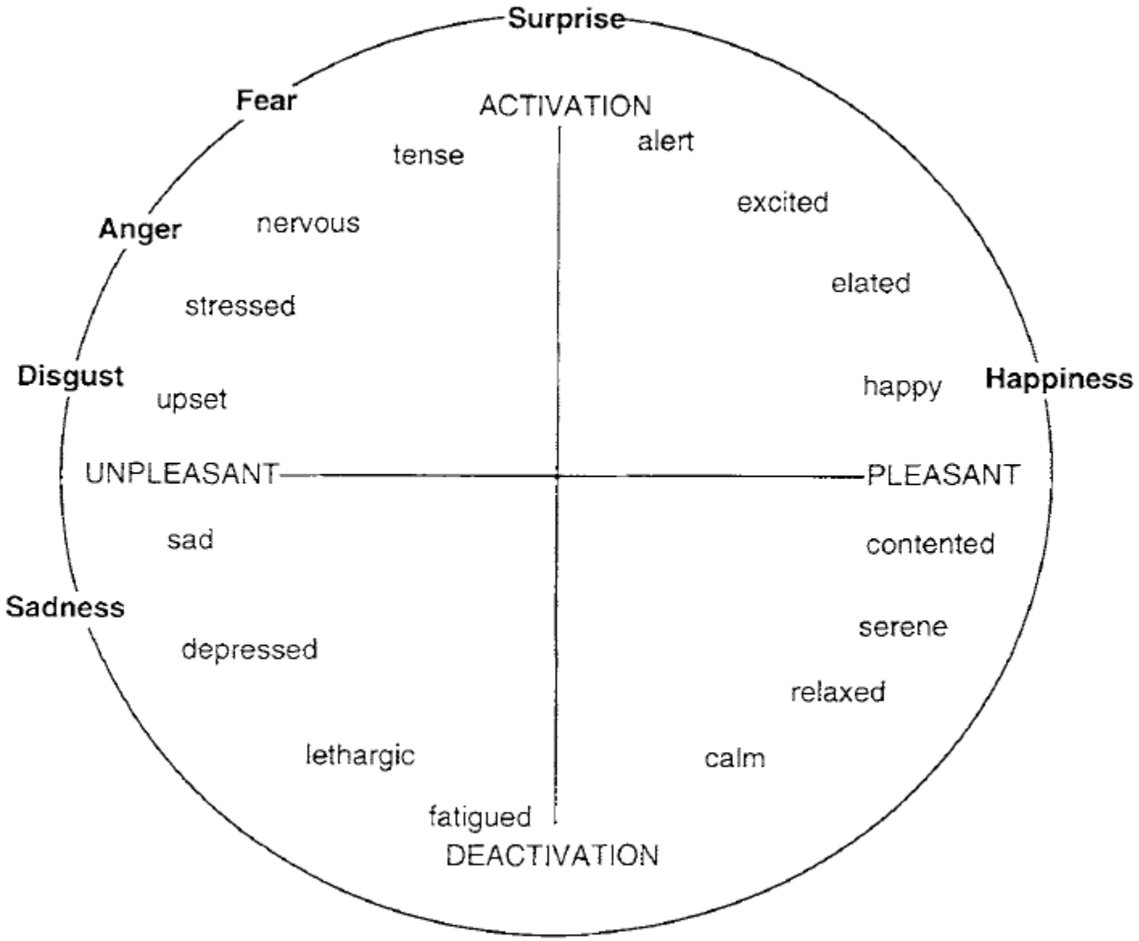
Al incorporar matices afectivos intermedios (*alerta, entusiasmo, serenidad, fatiga, depresión, tensión*), se evidencia una gradación circular de estados afectivos.



[ESQUEMA TEÓRICO · PASO 3 / 4]

Episodios emocionales prototípicos + Afecto nuclear

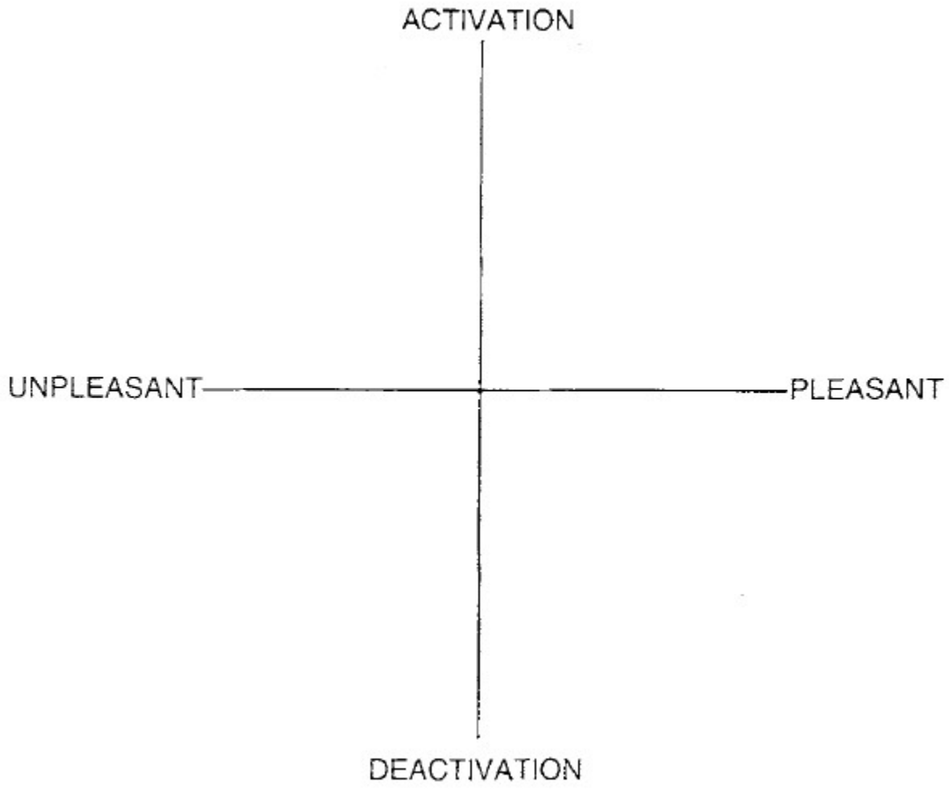
Los episodios emocionales se ordenan sobre una estructura analítica subyacente formada por dos ejes ortogonales: **Activación / Desactivación** (eje vertical) y **Placer / Displacer** (eje horizontal).



[ESQUEMA TEÓRICO · PASO 4 / 4]

Afecto nuclear

Al abstraer el plano cartesiano bidimensional del **afecto nuclear**, obtenemos una escala continua y medible donde ubicar cada reacción afectiva según su valencia (*Unpleasant / Pleasant*) y su energía (*Deactivation / Activation*).

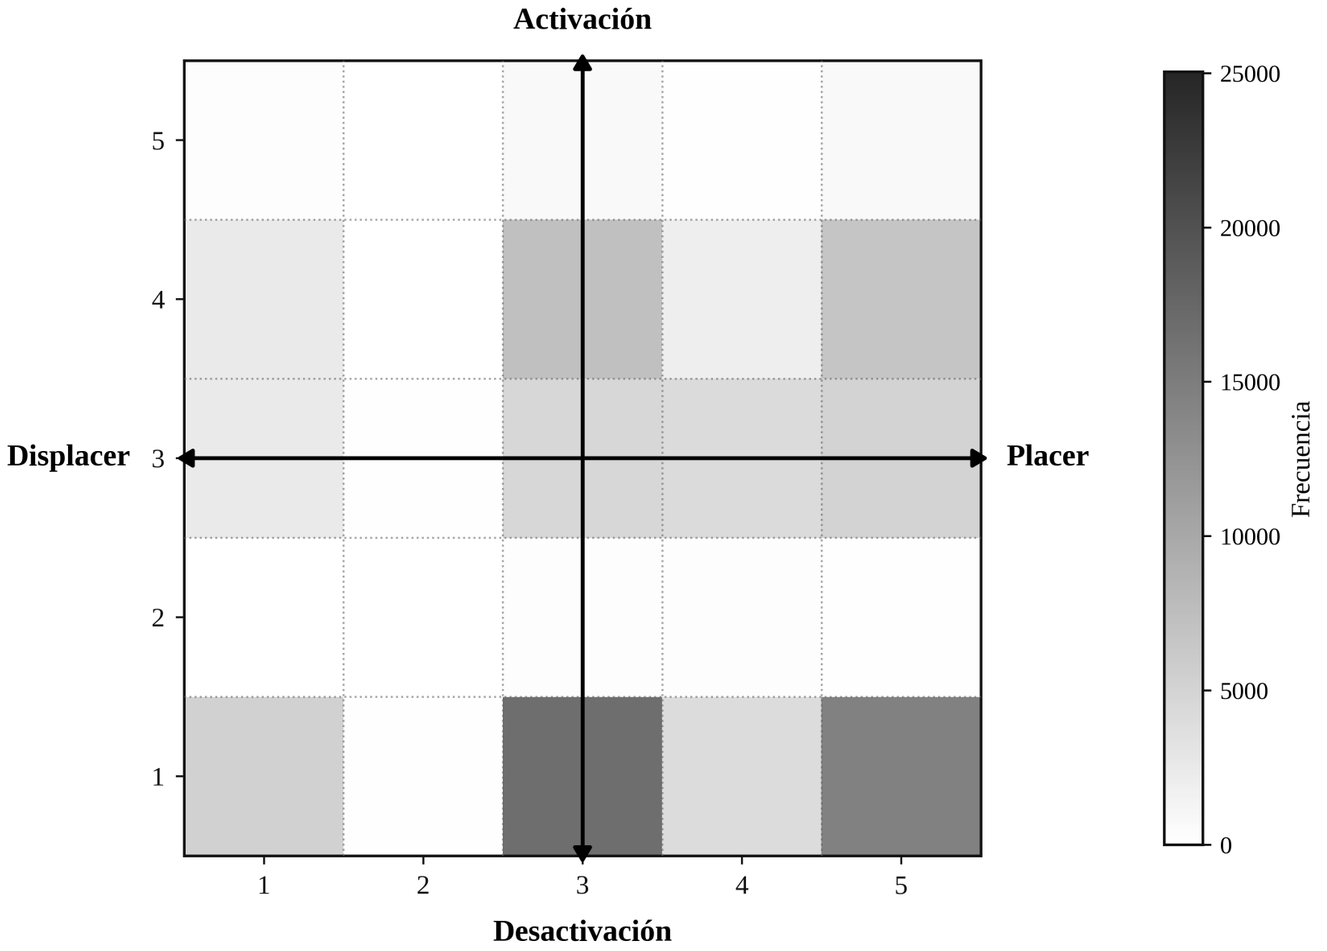


ESTRATEGIA 1 · SIN REENTRENAMIENTO

RoBERTuito Base

ARQUITECTURA: RoBERTuito-base-uncased
ABORDAJE: Rúbrica directa (Zero-Shot)
SALIDA: 5 niveles discretos por eje (1 a 5)

- **¿Cómo se lee el gráfico?** Cada celda del plano cartesiano cruza el nivel asignado en *Displacer/Placer* (eje X) y *Desactivación/Activación* (eje Y).
- Sin ajuste al contexto político local, el modelo concentra los casos en valores neutros o de baja activación (`Y = 1`) y no logra captar la ironía ni los términos partidarios.



ESTRATEGIA 2 · FINE-TUNING NOMINAL

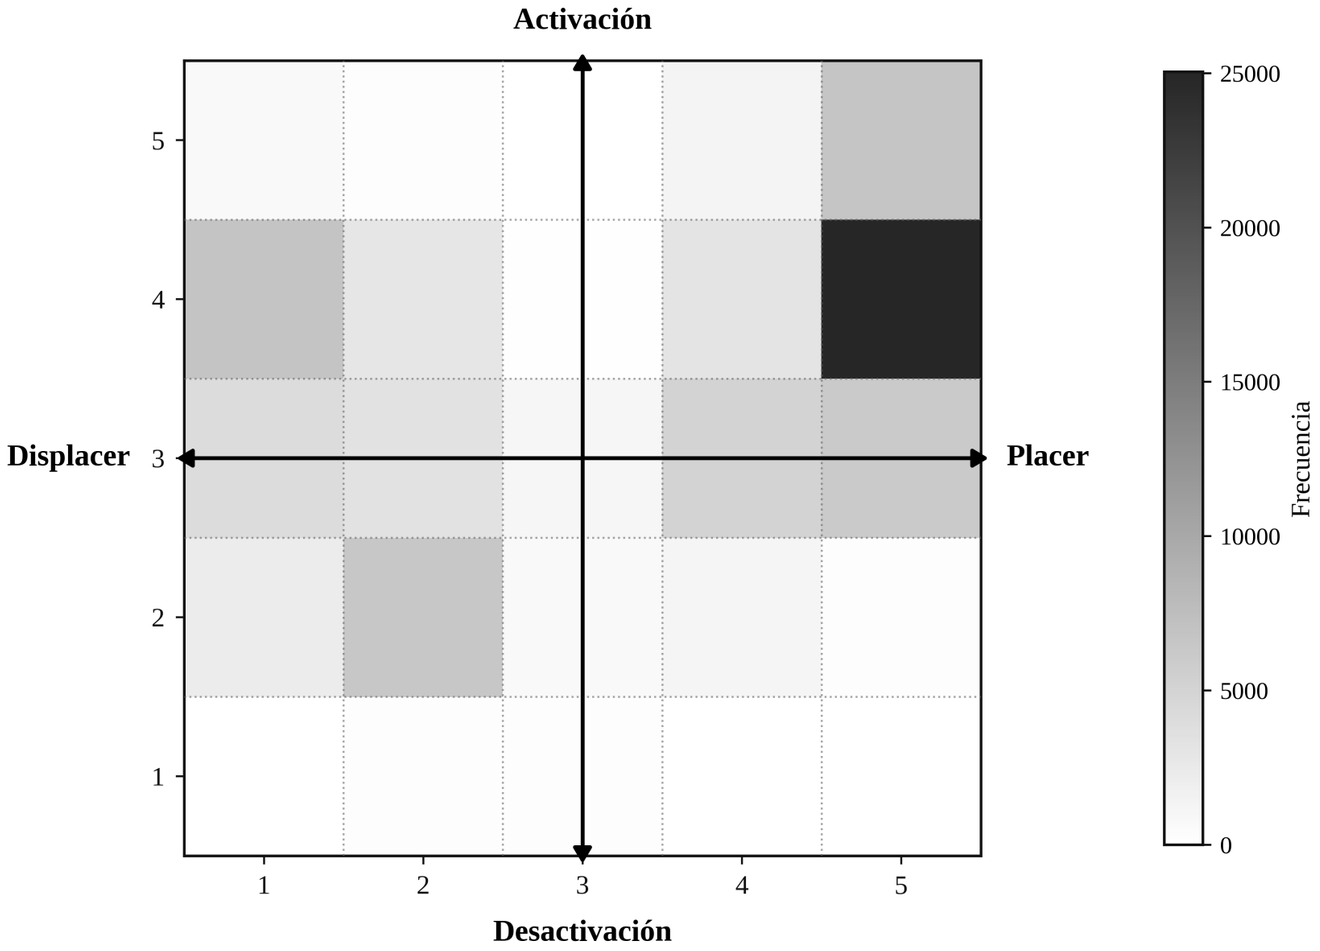
RoBERTuito Multiclase

OPTIMIZACIÓN: Función Softmax (Cross-Entropy)

ENTRENAMIENTO: Muestra anotada (n = 2.499)

SALIDA: 5 clases nominales independientes

- Al incorporar el aprendizaje sobre el corpus propio, el modelo reconoce la polarización afectiva y desplaza la distribución hacia los cuadrantes activos.
- **Límite del enfoque nominal:** La función *Softmax* asigna todo el peso a la categoría más probable, encasillando masivamente los comentarios en celdas discretas puntuales (como el bloque `(5, 4)`).



ESTRATEGIA 3 · FINE-TUNING ORDINAL

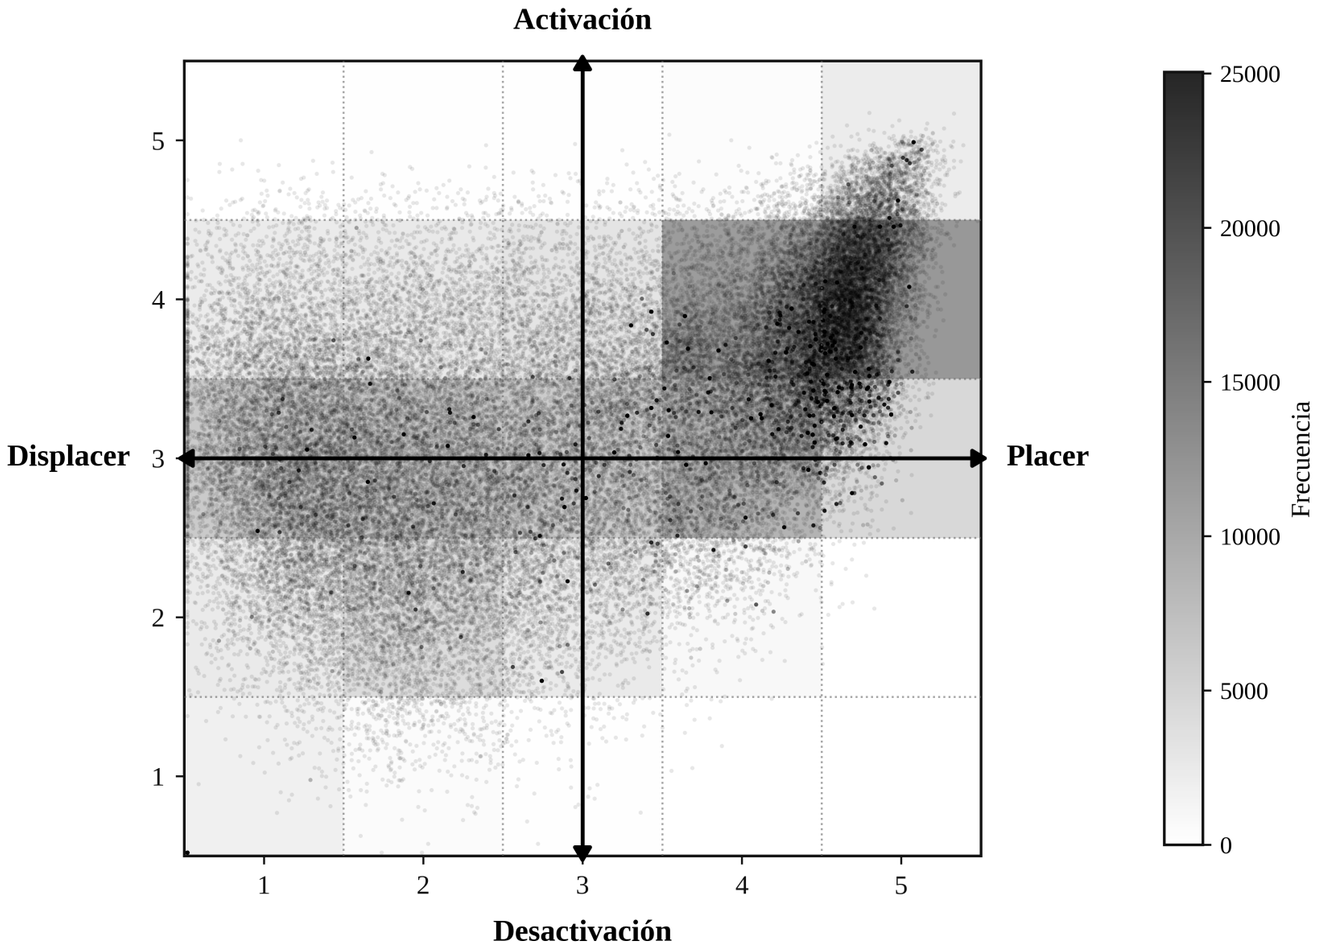
RoBERTuito Regresión

OPTIMIZACIÓN: Error Cuadrático Medio (MSE)

CAPA FINAL: 1 neurona lineal continua [1.0 - 5.0]

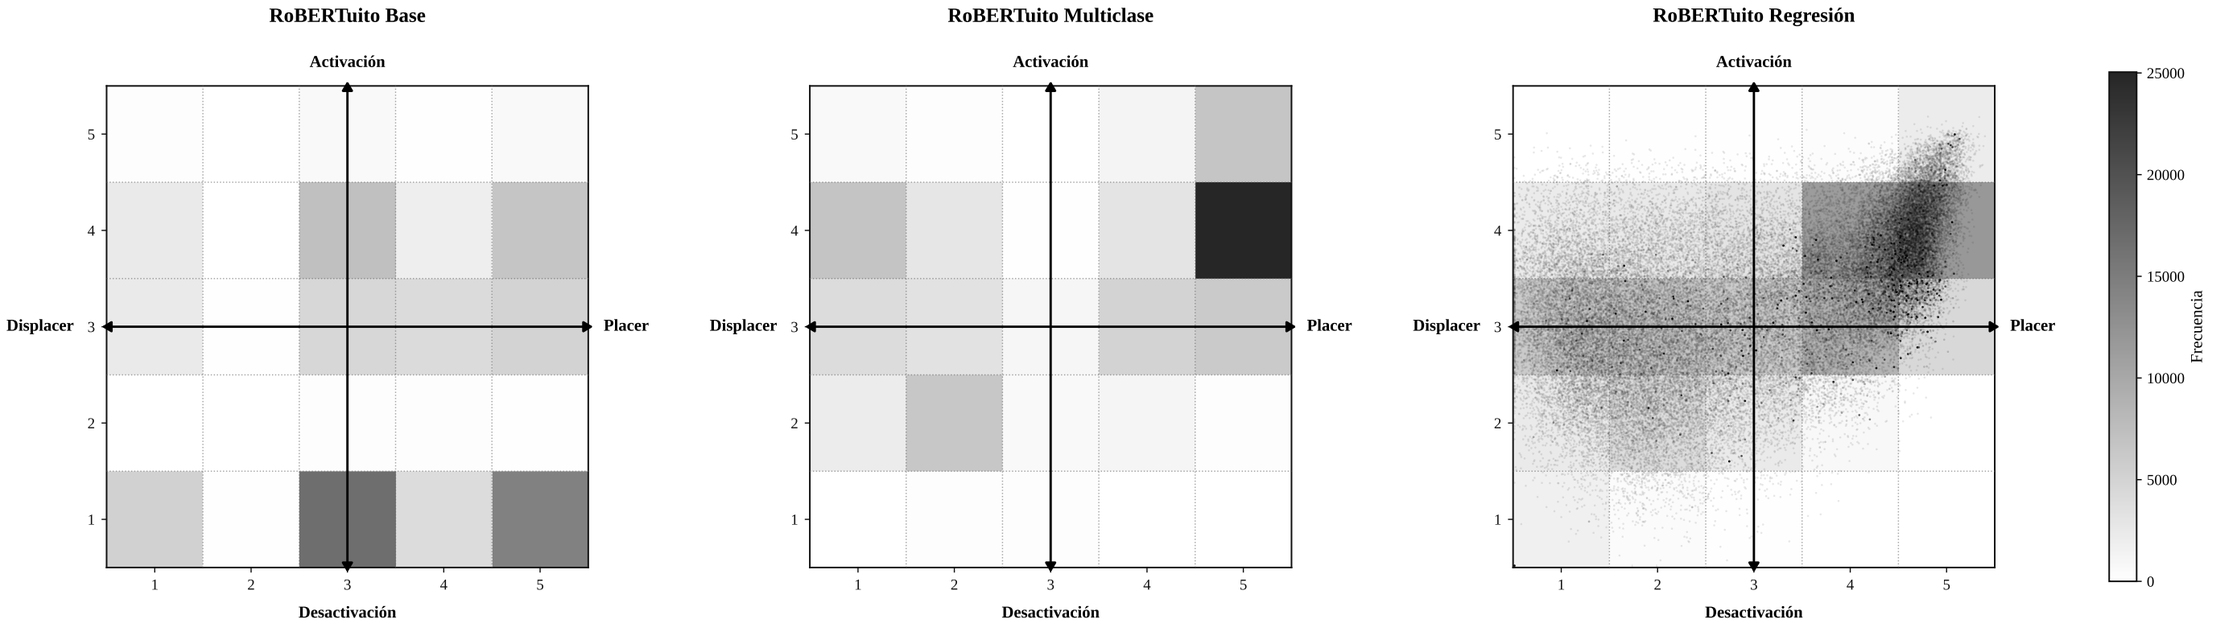
VISUALIZACIÓN: Grilla + Nube de puntos sin redondear

- Al tratar las dimensiones como un **continuo ordinal** y penalizar la distancia del error, cada comentario se ubica con coordenadas exactas en el plano del afecto nuclear.
- Permite observar la **estructura real de la discusión pública**: una transición orgánica desde el rechazo moderado/indignado hacia el núcleo de alta validación militante (placer + activación).



Del modelo base a la regresión ordinal: impacto en la medición

[CLIC EN LA IMAGEN PARA AMPLIAR · ESCALA UNIFICADA 0 – 25.000 CASOS]



1. ROBERTUITO BASE

Sin *fine-tuning* específico, no comprende el registro político local y distorsiona la distribución hacia el borde inferior.

2. ROBERTUITO MULTICLASE (SOFTMAX)

Captura la orientación general pero rigidiza el espacio afectivo en compartimentos estancos, perdiendo los matices intermedios.

3. ROBERTUITO REGRESIÓN (MSE)

Reconstruye la topografía continua del afecto nuclear, permitiendo medir grados de polarización afectiva y evitar inversiones polares.

Corpus y distribución de la muestra anotada

[n = 2.499 · N = 357.436 COMENTARIOS]

TABLA 1. DISTRIBUCIÓN MUESTRAL DE LAS DIMENSIONES PLACER/DISPLACER Y ACTIVACIÓN/DESACTIVACIÓN

Valor	Placer / Displacer		Activación / Desactivación	
	Frecuencia (n)	Porcentaje (%)	Frecuencia (n)	Porcentaje (%)
1 (Extremo inf.)	571	22,85%	357	14,29%
2	558	22,33%	433	17,33%
3 (Neutro / Medio)	322	12,89%	**818**	**32,73%**
4	363	14,53%	575	23,01%
5 (Extremo sup.)	**685**	**27,41%**	316	12,65%
Total	**2.499**	**100,00%**	**2.499**	**100,00%**

RECOLECCIÓN Y CODIFICACIÓN

Comentarios en Instagram (Oct 2023 – Dic 2024)

Publicaciones de imágenes generadas con inteligencia artificial por Javier Milei (elemento condensador en su contexto sociopolítico).

MUESTRA ALEATORIA: n = 2.499 (de N = 357.436)
ENTRENAMIENTO (90%): n_1 = 2.249 (semilla 42)
EVALUACIÓN (10%): n_2 = 250 (reserva estricta)
PREPROCESAMIENTO: preprocess_tweet (pysentimiento)

- **Placer / Displacer:** Distribución bimodal concentrada en los polos de rechazo (`1–2`: 45,2%) y apoyo (`5`: 27,4%).
- **Activación / Desactivación:** Distribución centrada en el nivel medio (`3`: 32,7%).

Operacionalización: ejemplos ilustrativos del manual de códigos

[TABLAS 7 Y 8 DEL ANEXO · ESCALA ORDINAL 1 A 5]

Dimensión Placer / Displacer

VALENCIA AFECTIVA

VALOR 1 Insultos, apodos de rechazo ("presiduende", "kukas"), crítica directa

"No se puede ser tan stupid0 no se puede ser tan colonizado mentalmente tan subordinado intelectualmente tan chiquito de pies cabeza y neuronas."

VALOR 2 Posición negativa sin insultos ni mayúsculas; desilusión

"Todo lo que iba a hacer, se transformó en otra cosa.. que vergonzoso."

VALOR 5 Palabras/emojis clave de apoyo ("VLLC", leones), mayúsculas, validación directa

"VAMOOOSSS JAVIER, BIENVENIDA Patricia 🙌🙌🙌 CUIDEMOS AMEMOS RESPETEMOS A NUESTRO HERMOSO PAIS🇦🇷LUCHEMOS SALGAMOS ADELANTE."

Dimensión Activación / Desactivación

MOVILIZACIÓN / ENERGÍA

VALOR 1 Sin emojis, sin signos de exclamación ni mayúsculas; baja intensidad

"Esperemos verlos sesionar para beneficio de la sociedad."

VALOR 3 Alto rechazo semántico pero articulado desde el agotamiento/tristeza (sin mayúsculas)

"Esoty re podrido del kirchnerismo vamos a probar algo nuevo gente no se puede salir ni a la veredad con la famillia por q te matan por un celular 😢😢."

VALOR 5 Emojis clave, exclamación, mayúsculas sostenidas y confrontación directa

"@monickant JAJAJAAJAJAJJAUAUAUAUAUA DALE CHAU (la enfe rma que viene a bardear sos vos mamu) besis"

Arquitecturas Transformer y estrategias de modelado

[2 MODELOS BASE × 4 ESTRATEGIAS DE CLASIFICACIÓN]

XLM-RoBERTa-Large-XNLI Davison (2020) / Conneau et al. (2020)

PARÁMETROS: 565 millones (24 capas) · 100 idiomas (2,5 TB)

Entrenado sobre fuentes formales multilingües (Wikipedia y sitios de noticias).

RoBERTuito-base-uncased Pérez et al. (2022)

PARÁMETROS: 108 millones (12 capas) · 500M tweets en español

Diseñado con tokenizador específico para redes sociales (identifica emojis, risas, URLs, menciones y hashtags).

ESTRATEGIA 01 · ZERO-SHOT MULTILINGÜE

XLM-RoBERTa-Large (Rúbrica)

Clasificación directa mediante indicación (*prompt* / rúbrica) con las categorías de Russell & Feldman Barrett (1999), sin ajuste de pesos.

ESTRATEGIA 02 · MODELO BASE EN ESPAÑOL

RoBERTuito Base (Rúbrica)

Evaluación directa del modelo preentrenado en tweets en español utilizando la misma rúbrica sin reentrenamiento local.

ESTRATEGIA 03 · FINE-TUNING MULTICLASE

RoBERTuito + Función Softmax

Reentrenamiento con los 2.249 casos anotados. Capa final de **5 salidas nominales independientes**: asigna la clase de mayor probabilidad sin medir distancia entre niveles.

ESTRATEGIA 04 · FINE-TUNING POR REGRESIÓN ORDINAL

RoBERTuito + Error Cuadrático Medio (MSE)

Adaptación de la capa final a **1 única neurona lineal continua (1,0 a 5,0)**. Optimización por MSE penalizando la distancia métrica del error entre categorías.

Ajuste del entrenamiento y criterios de evaluación

[ADAMW · LR = 2e-5 · BATCH = 16 · MAX_LEN = 128 TOKENS]

TABLA 2. PROGRESIÓN DEL ENTRENAMIENTO POR ÉPOCA Y MÉTRICAS DEL AJUSTE MULTICLASE (N = 250)

Tarea	Época	Eval Loss	Eval Accuracy	Macro F1	Precision	Recall
Placer / Displacer	1	1.1170	58.00%	0.4151	0.4814	0.4561
	2	0.9796	60.40%	0.5226	0.5677	0.5225
	3*	**0.9364**	**62.40%**	**0.5505**	**0.5579**	**0.5534**
	4	0.9724	58.40%	0.5209	0.5211	0.5227
Activación / Desactivación	1	1.5160	29.60%	0.1469	0.2208	0.2283
	2	1.3630	38.00%	0.3555	0.4090	0.3534
	3*	**1.3580**	**39.60%**	**0.3900**	**0.4622**	**0.3793**
	4	1.3750	39.20%	0.3764	0.4091	0.3707

* Punto óptimo seleccionado (menor Eval Loss para prevenir sobreajuste). Ambos modelos superan el azar estadístico (20%).

CRITERIOS DE EVALUACIÓN (APARTADO 3.1.1)

¿Por qué Exactitud Tolerante (±1) y Correlaciones?

En el estudio de la **polarización afectiva**, no todos los errores de clasificación tienen el mismo costo sustantivo:

- **Error grave (Inversión polar):** Confundir un extremo displacer (`valor 1`) con un extremo placer (`valor 5`) invierte el sentido político del comentario.
- **Error leve (Intensidad):** Confundir un displacer extremo (`valor 1`) con uno moderado (`valor 2`) conserva la dirección del afecto.
- Por ello se evalúa **Acc Exacta**, **Acc Tolerante (±1)**, **F1 Macro** y los coeficientes **Pearson (*r*)** y **Spearman (*ρ*)**.

Evaluación global en la dimensión Placer / Displacer

[APARTADO 3.1.2 · MUESTRA DE EVALUACIÓN n = 250]

TABLA 3. MÉTRICAS GLOBALES DE DESEMPEÑO Y CONCORDANCIA PARA LA DIMENSIÓN PLACER/DISPLACER (N = 250)

Modelo	Acc Exacta	Acc Tol (±1)	Macro F1	Prec	Rec	Pearson (*r*)	Spearman (*ρ*)
RoBERTuito Regresión	**69.60%**	**98.40%**	**0.6542**	**0.6559**	**0.6623**	**0.9436**	**0.9185**
RoBERTuito Multiclase	62.40%	88.40%	0.5505	0.5579	0.5534	0.7877	0.7752
XLM-RoBERTa Large	30.00%	58.00%	0.2872	0.3301	0.2869	0.1509	0.1513
RoBERTuito Base	29.20%	50.40%	0.2333	0.2356	0.2344	0.1186	0.1412

ACC TOLERANTE (±1) · REGRESIÓN

98,40%

+10 pp frente al modelo Multiclase (88,40%)

CORRELACIÓN LINEAL Y DE RANGO

r = 0,94 · ρ = 0,92

Relación muy fuerte (vs. r = 0,79 en Multiclase)

EFECTO DEL FINE-TUNING

×2 Rendimiento

Duplica Acc Exacta y F1 Macro de modelos base

MODELOS BASE (SIN AJUSTE)

r = 0,15 / 0,12

XLM-R supera en solo 2 casos a RoBERTuito Base

RELEVANCIA DE LA REGRESIÓN ORDINAL

Al optimizar por MSE sobre embeddings transformer, el margen de error se reduce al mínimo (98,40% dentro de ±1 nivel), evitando inversiones polares en la lectura de comentarios.

COMPORTAMIENTO DE LOS MODELOS BASE

Sin reentrenamiento, las correlaciones son débiles. La leve ventaja de *XLM-RoBERTa Large* sobre *RoBERTuito Base* (30,0% vs. 29,2%) responde a su mayor escala (565M en 24 capas vs. 108M en 12 capas).

Evaluación global en la dimensión Activación / Desactivación

[APARTADO 3.1.3 · MUESTRA DE EVALUACIÓN n = 250]

TABLA 4. MÉTRICAS GLOBALES DE DESEMPEÑO Y CONCORDANCIA PARA LA DIMENSIÓN ACTIVACIÓN/DESACTIVACIÓN (N = 250)

Modelo	Acc Exacta	Acc Tol (±1)	Macro F1	Prec	Rec	Pearson (*r*)	Spearman (*ρ*)
RoBERTuito Regresión	**48.40%**	**92.80%**	**0.4450**	**0.5008**	**0.4390**	**0.7326**	**0.7170**
RoBERTuito Multiclase	39.60%	84.00%	0.3900	0.4622	0.3793	0.5937	0.5825
RoBERTuito Base	20.00%	55.20%	0.1710	0.2536	0.1870	−0.0648	−0.0664
XLM-RoBERTa Large	12.40%	44.00%	0.1138	0.1962	0.1544	−0.0537	−0.0271

ACC TOLERANTE (±1) · REGRESIÓN

92,80%

Frente a 84,00% en Multiclase y 55,20% en Base

CONSISTENCIA DIRECCIONAL

r = 0,73 · ρ = 0,72

Relación fuerte que captura la tendencia afectiva

ACC EXACTA VS. AZAR (20%)

48,40%

Supera ampliamente el azar (XLM-R cae a 12,40%)

VENTAJA DE DOMINIO LINGÜÍSTICO

Tweets > Wiki

RoBERTuito Base supera a XLM-RoBERTa en coloquial

¿POR QUÉ ES MÁS COMPLEJA ESTA DIMENSIÓN EN PLN?

Mientras el placer/displacer tiene marcadores léxicos explícitos (elogios, insultos), la activación es contextual: un **alto displacer** puede expresarse con *alta activación* (ira, indignación) o con *fuerte desactivación* (tristeza, decepción, resignación).

PESO DEL CORPUS DE PREENTRENAMIENTO

En esta dimensión sutil, *RoBERTuito Base* (entrenado con tweets coloquiales en español) supera claramente a *XLM-RoBERTa Large* (entrenado en Wikipedia y noticias), que queda por debajo del azar estadístico (12,40%).

Desempeño discriminativo por nivel (F1-Score): polos vs. matices

[APARTADOS 3.2.1 Y 3.2.2 · COMPROMISO ENTRE MSE Y SOFTMAX]

TABLA 5. F1-SCORE POR NIVEL Y MACRO F1 · PLACER / DISPLACER (N = 250)

Modelo	Nivel 1	Nivel 2	Nivel 3	Nivel 4	Nivel 5	Macro F1
RoBERTuito Regresión	**0.75**	0.61	**0.53**	**0.52**	**0.86**	**0.6542**
RoBERTuito Multiclase	0.70	**0.62**	0.38	0.29	0.76	0.5505
XLM-RoBERTa Large	0.35	0.30	0.29	0.17	0.33	0.2872
RoBERTuito Base	0.37	0.32	0.00	0.10	0.37	0.2333

TABLA 6. F1-SCORE POR NIVEL Y MACRO F1 · ACTIVACIÓN / DESACTIVACIÓN (N = 250)

Modelo	Nivel 1	Nivel 2	Nivel 3	Nivel 4	Nivel 5	Macro F1
RoBERTuito Regresión	0.41	**0.45**	**0.57**	**0.49**	0.31	**0.4450**
RoBERTuito Multiclase	**0.43**	0.35	0.45	0.35	**0.37**	0.3900
RoBERTuito Base	0.20	0.13	0.19	0.27	0.06	0.1710
XLM-RoBERTa Large	0.04	0.18	0.05	0.16	0.13	0.1138

NIVELES INTERMEDIOS (2, 3 Y 4) → GANA REGRESIÓN (MSE)

Con idéntica arquitectura e hiperparámetros, la optimización por MSE supera holgadamente a Softmax en las posiciones moderadas e intermedias en ambas dimensiones (ej. `0,53 vs 0,38` en Nivel 3 de Placer y `0,57 vs 0,45` en Activación).

POLOS EXTREMOS (1 Y 5) → COMPITE MULTICLASE (SOFTMAX)

En Activación/Desactivación, Multiclase conserva ventaja en el `Nivel 1 (0,43 vs 0,41)` y `Nivel 5 (0,37 vs 0,31)`. Softmax amplifica no linealmente las probabilidades ante marcadores léxicos extremos.

EXPLICACIÓN: COMPRESIÓN DE BORDES EN MSE

Al acotar predicciones en `[1.0, 5.0]` y penalizar desviaciones, la regresión dispone de solo **0,5 unidades** de margen en los extremos (1 y 5), frente al ancho completo de **1,0 unidad** en los niveles 2, 3 y 4.

Conclusiones: tres hallazgos principales y agenda futura

[APARTADO 4 · SÍNTESIS METODOLÓGICA]

HALLAZGO 01 · FUNCIÓN DE PÉRDIDA

Regresión Ordinal (MSE) vs. Multiclase (Softmax)

Tratar el afecto nuclear como un continuo mediante MSE **evitó la inversión polar** (alcanzando **98,40%** y **92,80%** de exactitud tolerante) y capturó mejor los matices intermedios (niveles 2, 3 y 4).

Criterio de uso: Si solo interesa aislar polarización extrema (polos 1 y 5), *Multiclase* es competitivo; para modelar la totalidad del gradiente afectivo, la *Regresión Ordinal* es superior.

HALLAZGO 02 · DIMENSIONES DEL AFECTO

Asimetría estructural entre dimensiones

Placer / Displacer ofrece marcadores léxicos explícitos (insultos, elogios, términos partidarios) que facilitan la discriminación vectorial.

Activación / Desactivación es sutil y contextual: un fuerte displacer puede articularse desde la *alta activación* (ira, indignación) o desde la *baja activación* (tristeza, resignación), volviendo crítica la elección de la arquitectura y la función de pérdida.

HALLAZGO 03 · DOMINIO LINGÜÍSTICO

Preentrenamiento específico y adaptación local

`RoBERTuito Base` demostró un desempeño superior al interactuar con el registro coloquial de redes sociales en español frente a modelos multilingües generales.

A su vez, el **reentrenamiento (*fine-tuning*)** con una muestra anotada propia **duplicó las métricas de rendimiento**, superando las limitaciones de los modelos base ante la jerga política argentina.

// LIMITACIONES Y LÍNEAS FUTURAS

1. Arquitecturas ordinales: Contrastar esta formulación básica (neurona lineal + MSE) con arquitecturas específicas de la literatura de *ordinal learning*. | **2. Validación de anotación:** Implementar protocolos de anotación múltiple cruzada y métricas formales de acuerdo inter-jueces (*Kappa de Cohen* | *Alpha de Krippendorff*).