JORNADAS DE JÓVENES INVESTIGADORES · INSTITUTO DE INVESTIGACIONES GINO GERMANI

Análisis comparativo de modelos **RoBERTa** y estrategias de **clasificación** para la medición **ordinal** de la **polarización afectiva** a partir del **modelo circunflejo del afecto**

Agustín Nielsen (IIGG-FSOC-UBA)
Estudiante avanzado Lic. en Sociología (FSOC-UBA)

EJE 9 · TEORÍAS, EPISTEMOLOGÍAS Y METODOLOGÍAS
PLN · ANÁLISIS DE SENTIMIENTO · REGRESIÓN ORDINAL

Planteo del problema y definiciones conceptuales

¿Qué? Procesos de polarización afectiva

Definición: "Distancia en grados de las emociones de votantes de distintos partidos al observar un mensaje político", mediada por el aumento de la incivilidad en redes y la urgencia de interactuar validando o confrontando (Calvo & Aruguete, 2023, pp. 56–57).

Las reacciones afectivas surgen frente a la *representación* dada por las imágenes generadas con IA (entendidas como elemento condensador en su contexto sociopolítico).

¿Cómo? Clasificación automática · Análisis de sentimiento

Definición: "La tarea de clasificar sentimiento, la orientación positiva o negativa que un escritor expresa hacia un objeto" (Jurafsky & Martin, 2026, p. 92).

El sentimiento es bipolar y excluyente, y se da siempre *respecto a un otro* ante un estímulo: es el **producto de una relación social** y del posicionamiento de un actor frente a otro en los comentarios.

Afecto nuclear

Russell & Feldman Barrett (1999)

"El sentimiento más elemental accesible desde la consciencia" (p. 806). Puede o no estar referido a un objeto y varía a través del tiempo.

> **Placer / Displacer:** "qué tan bien le va a uno" (p. 809).

> **Activación / Desactivación:** "refiere a la sensación de movilización o energía" (p. 809).

Episodios emocionales prototípicos

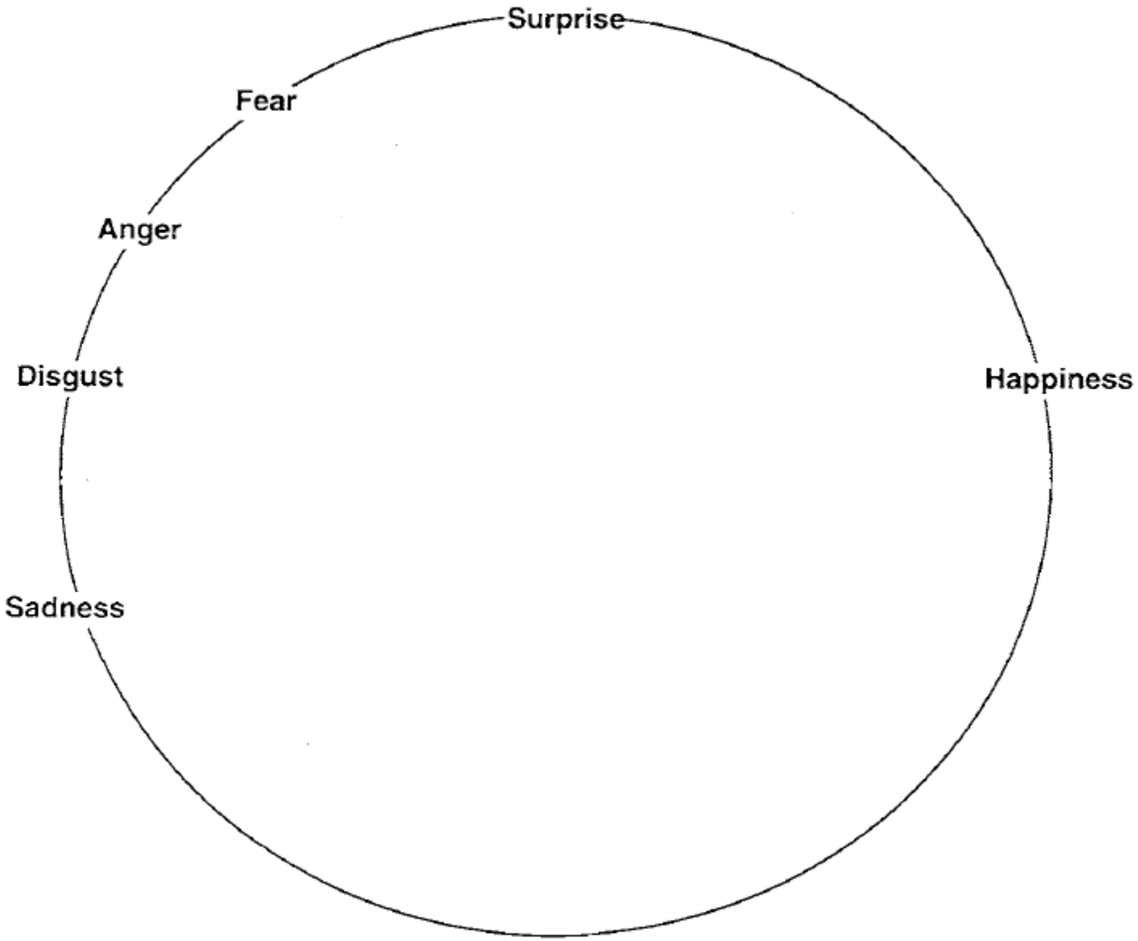
Russell & Feldman Barrett (1999)

- **Definición:** "Un grupo complejo de eventos interrelacionados referidos a un objeto específico" (p. 806) — *ej.: ira, euforia, miedo o asco*.
- Cualitativamente complejos de medir por fuera de casos ejemplares.
- Se manifiestan en períodos específicos con un principio y fin.
- Útiles desde la autocategorización, pero presentan dificultades para atribuirlos a los sujetos.

[ESQUEMA TEÓRICO · PASO 1 / 4]

Episodios emocionales prototípicos

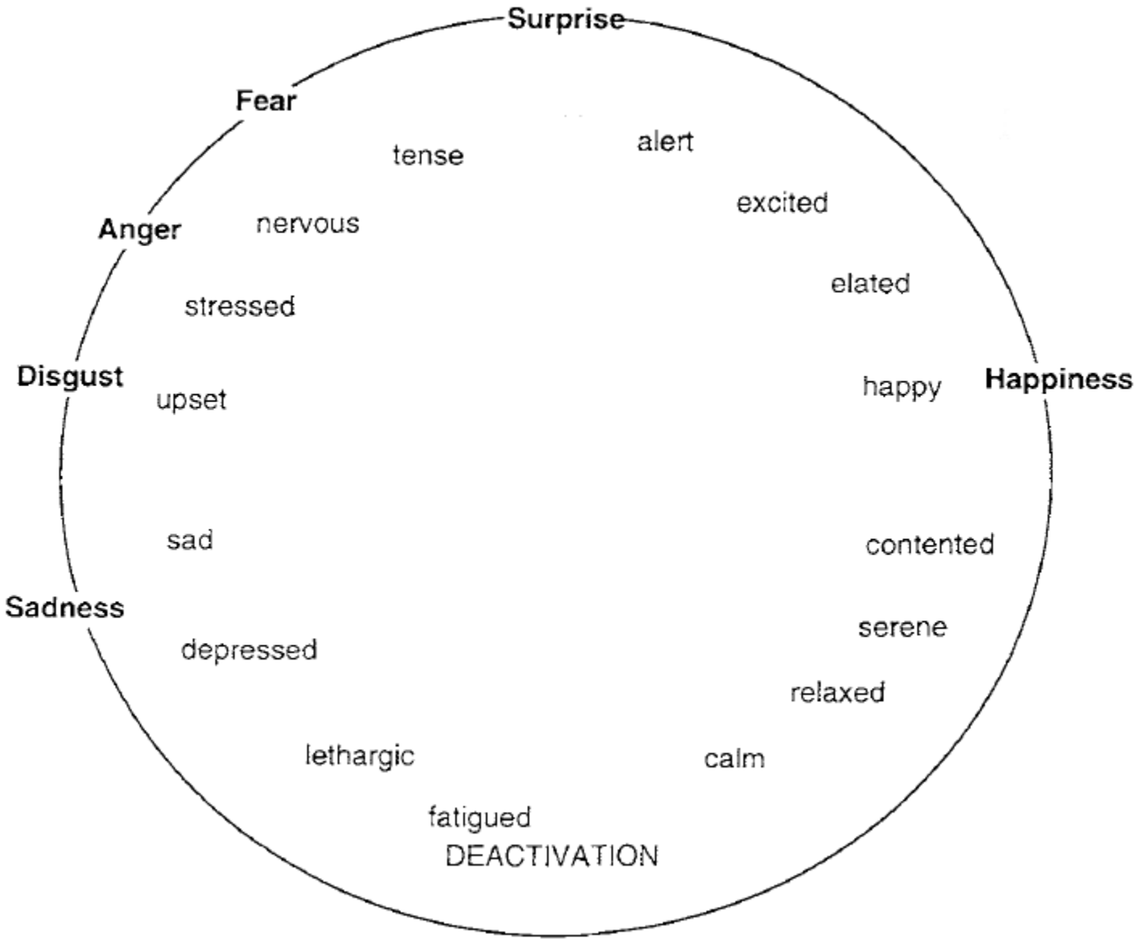
Las emociones discretas clásicas (*sorpresa, miedo, ira, asco, tristeza, felicidad*) se ubican como referencias prototípicas alrededor del perímetro, pero no agotan el espacio afectivo continuo.



[ESQUEMA TEÓRICO · PASO 2 / 4]

Episodios emocionales prototípicos

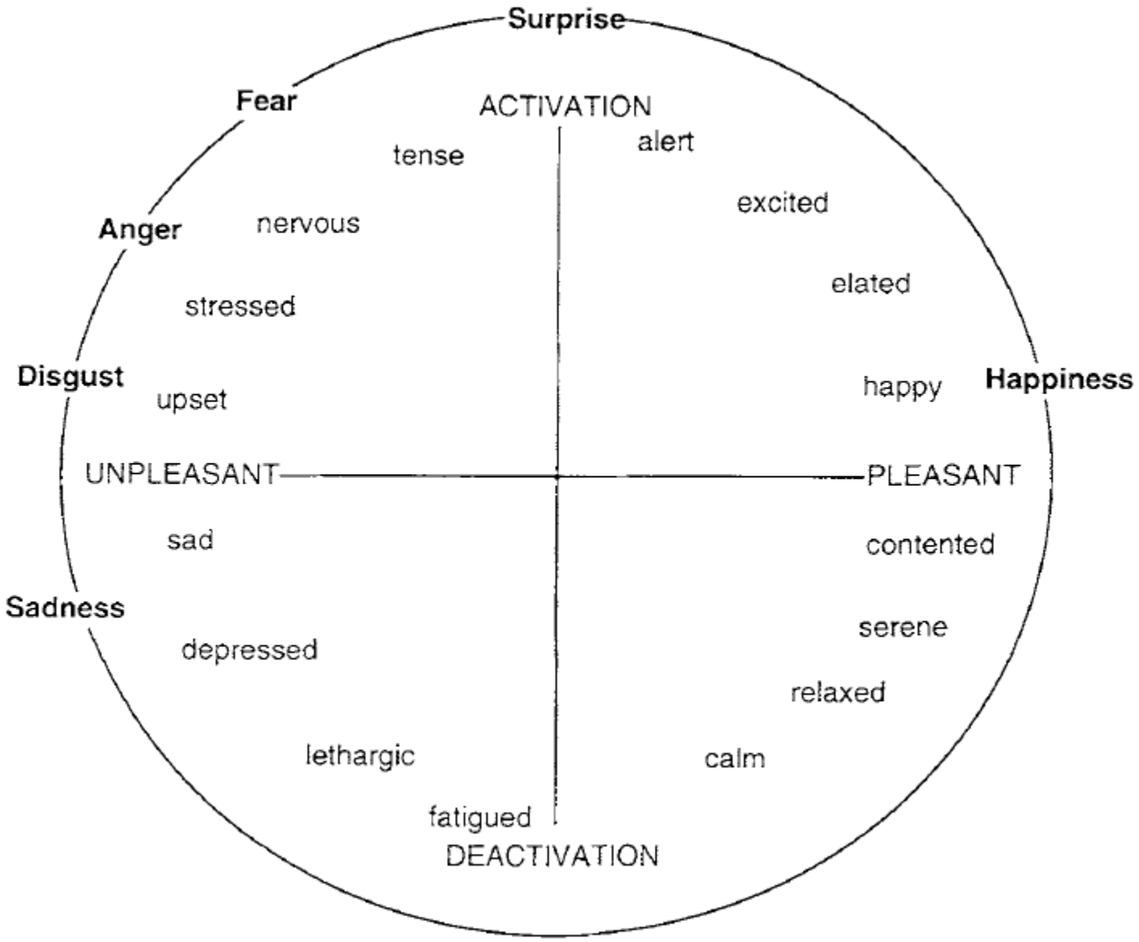
Al incorporar matices afectivos intermedios (*alerta, entusiasmo, serenidad, fatiga, depresión, tensión*), se evidencia una gradación circular de estados afectivos.



[ESQUEMA TEÓRICO · PASO 3 / 4]

Episodios emocionales prototípicos + Afecto nuclear

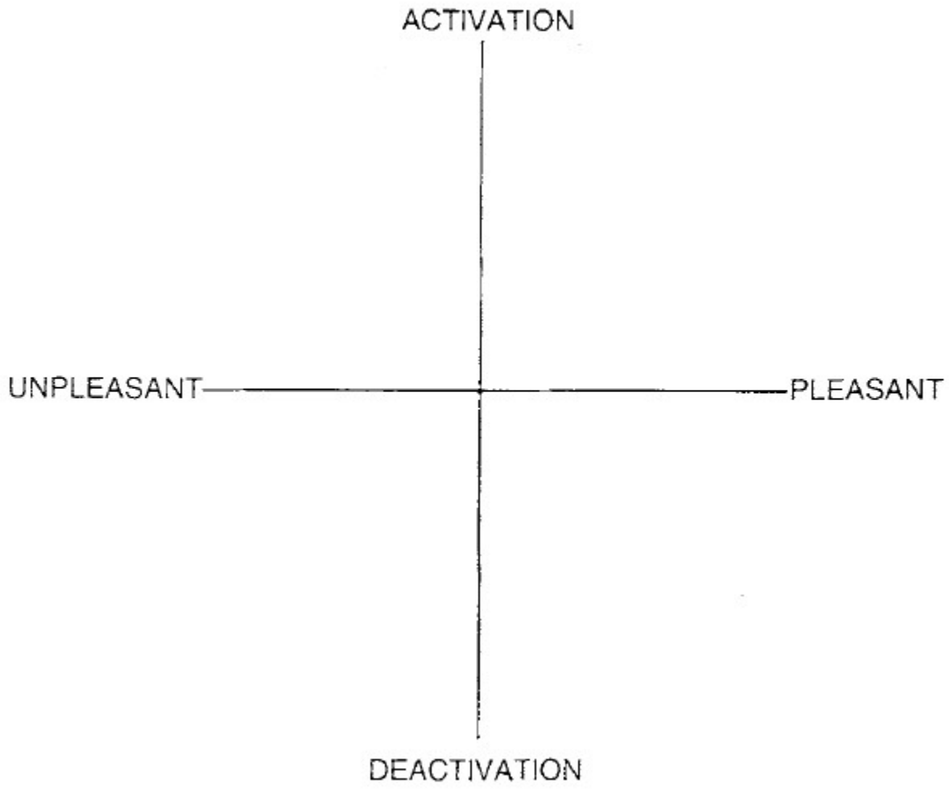
Los episodios emocionales se ordenan sobre una estructura analítica subyacente formada por dos ejes ortogonales: **Activación / Desactivación** (eje vertical) y **Placer / Displacer** (eje horizontal).



[ESQUEMA TEÓRICO · PASO 4 / 4]

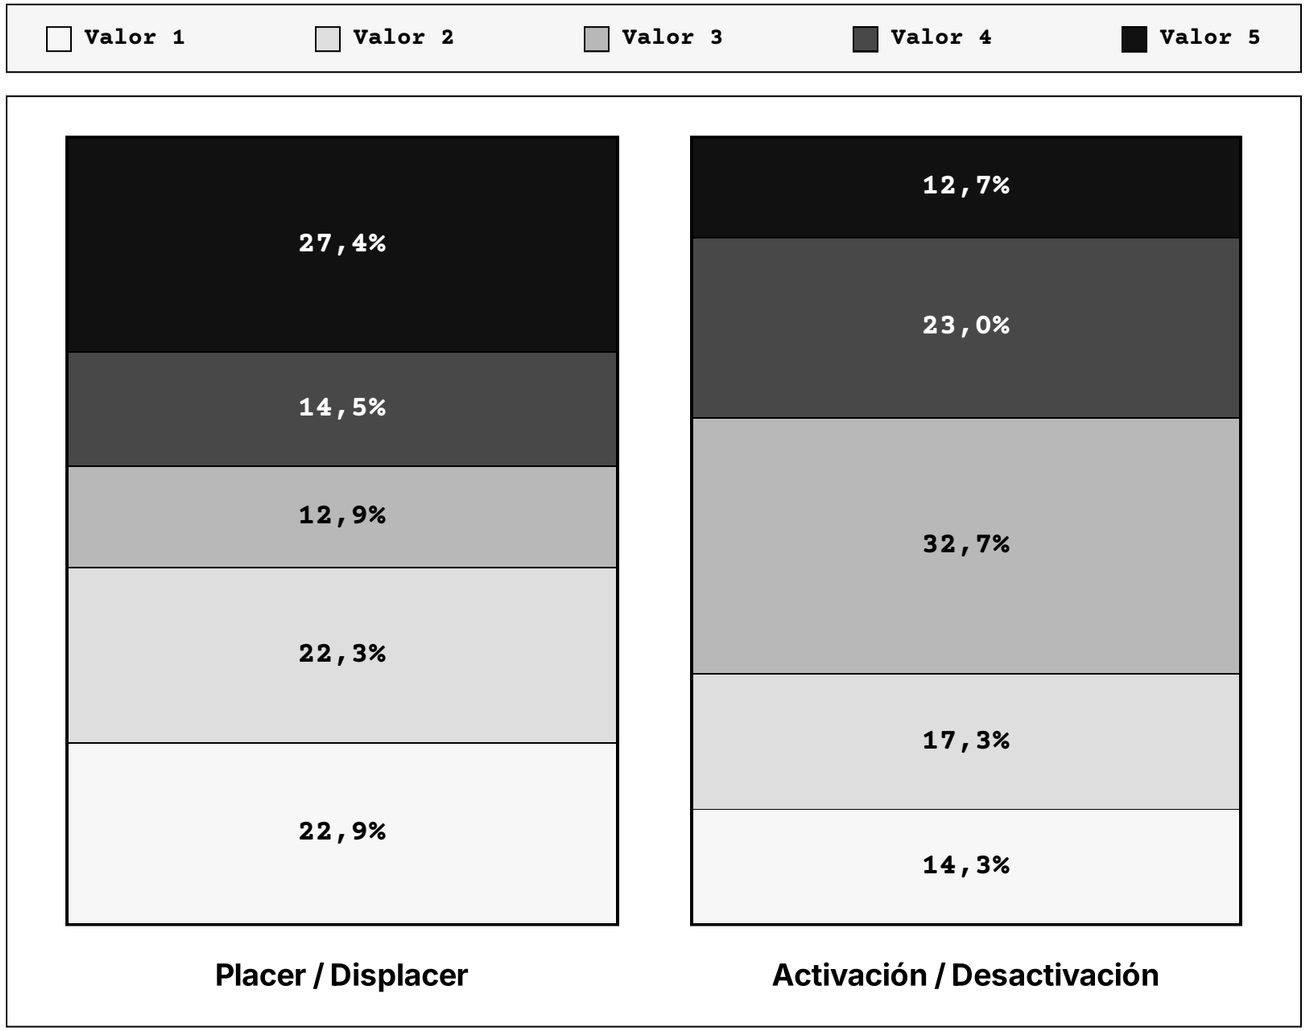
Afecto nuclear

Al abstraer el plano cartesiano bidimensional del **afecto nuclear**, obtenemos una escala continua y medible donde ubicar cada reacción afectiva según su valencia (*Unpleasant / Pleasant*) y su energía (*Deactivation / Activation*).



Corpus y distribución de la muestra anotada

GRÁFICO 1. DISTRIBUCIÓN DE LA MUESTRA DE ENTRENAMIENTO SEGÚN DIMENSIÓN



Fuente: Elaboración propia.

CORPUS

Comentarios en Instagram (Oct 2023 – Dic 2024)

Publicaciones de imágenes generadas con inteligencia artificial por Javier Milei.

MUESTRA: n = 2.499 (N = 357.436)

ENTRENAMIENTO (90%): n_1 = 2.249 (semilla 42)

EVALUACIÓN (10%): n_2 = 250

PREPROCESAMIENTO: preprocess_tweet (pysentimiento)

Ejemplos ilustrativos del manual de códigos

Dimensión Placer / Displacer

VALOR 1 Insultos, apodos de rechazo ("presiduende", "kukas"), crítica directa

"No se puede ser tan stupid0 no se puede ser tan colonizado mentalmente tan subordinado intelectualmente tan chiquito de pies cabeza y neuronas."

VALOR 2 Posición negativa sin insultos ni mayúsculas; desilusión

"Todo lo que iba a hacer, se transformó en otra cosa.. que vergonzoso."

VALOR 5 Palabras/emojis clave de apoyo ("VLLC", leones), mayúsculas, validación directa

"VAMOOOSSS JAVIER, BIENVENIDA Patricia 🙌🙌🙌 CUIDEMOS AMEMOS RESPETEMOS A NUESTRO HERMOSO PAIS🇦🇷LUCHEMOS SALGAMOS ADELANTE."

Dimensión Activación / Desactivación

VALOR 1 Sin emojis, sin signos de exclamación ni mayúsculas; baja intensidad

"Esperemos verlos sesionar para beneficio de la sociedad."

VALOR 3 Alto rechazo semántico pero articulado desde el agotamiento/tristeza (sin mayúsculas)

"Esoty re podrido del kirchnerismo vamos a probar algo nuevo gente no se puede salir ni a la veredad con la famillia por q te matan por un celular 😢😢."

VALOR 5 Emojis clave, exclamación, mayúsculas sostenidas y confrontación directa

"@xxxxx JAJAJAAJAJAJJAUAUAUAUAUA DALE CHAU (la enfe rma que viene a bardear sos vos mamu) besis"

Arquitecturas Transformer y estrategias de modelado

XLM-RoBERTa-Large-XNLI Davison (2020) / Conneau et al. (2020)

PARÁMETROS: 565 millones (24 capas) · 100 idiomas (2,5 TB)

Entrenado sobre fuentes formales multilingües (Wikipedia y sitios de noticias).

RoBERTuito-base-uncased Pérez et al. (2022)

PARÁMETROS: 108 millones (12 capas) · 500M tweets en español

Diseñado con tokenizador específico para redes sociales (identifica emojis, risas, URLs, menciones y hashtags).

ESTRATEGIA 01

XLM-RoBERTa-Large

Clasificación directa mediante indicación (*prompt* / rúbrica) con las categorías de Russell & Feldman Barrett (1999), sin ajuste de pesos.

ESTRATEGIA 02

RoBERTuito Base

Evaluación directa del modelo preentrenado en tweets en español utilizando la misma rúbrica sin reentrenamiento local.

ESTRATEGIA 03 · FINE-TUNING MULTICLASE

RoBERTuito + Función Softmax

Reentrenamiento con los 2.249 casos anotados. Capa final de **5 salidas nominales independientes**: asigna la clase de mayor probabilidad sin medir distancia entre niveles.

ESTRATEGIA 04 · FINE-TUNING POR REGRESIÓN ORDINAL

RoBERTuito + Error Cuadrático Medio (MSE)

Adaptación de la capa final a **1 única neurona lineal continua (1,0 a 5,0)**.
Optimización por MSE penalizando la distancia métrica del error entre categorías.

Ajuste del entrenamiento y criterios de evaluación

[ADAMW · LR = 2e-5 · BATCH = 16 · MAX_LEN = 128 TOKENS]

TABLA 2. PROGRESIÓN DEL ENTRENAMIENTO POR ÉPOCA Y EVALUACIÓN

Tarea	Época	Eval Loss	Eval Accuracy	Macro F1	Precision	Recall
Placer / Displacer	1	1.1170	58.00%	0.4151	0.4814	0.4561
	2	0.9796	60.40%	0.5226	0.5677	0.5225
	3	**0.9364**	**62.40%**	**0.5505**	**0.5579**	**0.5534**
	4	0.9724	58.40%	0.5209	0.5211	0.5227
Activación / Desactivación	1	1.5160	29.60%	0.1469	0.2208	0.2283
	2	1.3630	38.00%	0.3555	0.4090	0.3534
	3	**1.3580**	**39.60%**	**0.3900**	**0.4622**	**0.3793**
	4	1.3750	39.20%	0.3764	0.4091	0.3707

CRITERIOS DE EVALUACIÓN

¿Por qué Exactitud Tolerante (±1) y Correlaciones?

En estudios de polarización, no todos los errores tienen el mismo costo:

- **Error de inversión polar:** Confundir un extremo displacer (`valor 1`) con un extremo placer (`valor 5`) invierte el sentido del comentario.
- **Error de intensidad:** Confundir un displacer extremo (`valor 1`) con uno moderado (`valor 2`) conserva la dirección del afecto.
- Por ello se evalúa **Acc Exacta**, **Acc Tolerante (±1)**, **F1 Macro** y los coeficientes **Pearson (*r*)** y **Spearman (*ρ*)**.

Evaluación global en la dimensión Placer / Displacer

TABLA 3. MÉTRICAS GLOBALES DE DESEMPEÑO PARA LA DIMENSIÓN PLACER/DISPLACER

Modelo	Acc Exacta	Acc Tol (±1)	Macro F1	Prec	Rec	Pearson (*r*)	Spearman (*ρ*)
RoBERTuito Regresión	**69.60%**	**98.40%**	**0.6542**	**0.6559**	**0.6623**	**0.9436**	**0.9185**
RoBERTuito Multiclase	62.40%	88.40%	0.5505	0.5579	0.5534	0.7877	0.7752
XLM-RoBERTa Large	30.00%	58.00%	0.2872	0.3301	0.2869	0.1509	0.1513
RoBERTuito Base	29.20%	50.40%	0.2333	0.2356	0.2344	0.1186	0.1412

ACC TOLERANTE (±1) · REGRESIÓN

98,40%

+10 pp frente al modelo Multiclase (88,40%)

CORRELACIÓN LINEAL Y DE RANGO

r = 0,94 · ρ = 0,92

Relación muy fuerte (vs. r = 0,79 en Multiclase)

EFECTO DEL FINE-TUNING

×2 Rendimiento

Duplica Acc Exacta y F1 Macro de modelos base

MODELOS BASE (SIN AJUSTE)

r = 0,15 / 0,12

XLM-R supera en solo 2 casos a RoBERTuito Base

RELEVANCIA DE LA REGRESIÓN ORDINAL

Al optimizar por MSE sobre embeddings transformer, el margen de error se reduce al mínimo (98,40% dentro de ±1 nivel), evitando inversiones polares en la lectura de comentarios.

COMPORTAMIENTO DE LOS MODELOS BASE

Sin reentrenamiento, las correlaciones son débiles. La leve ventaja de *XLM-RoBERTa Large* sobre *RoBERTuito Base* (30,0% vs. 29,2%) responde a su mayor escala (565M en 24 capas vs. 108M en 12 capas).

Evaluación global en la dimensión Activación / Desactivación

TABLA 4. MÉTRICAS GLOBALES DE DESEMPEÑO PARA LA DIMENSIÓN ACTIVACIÓN/DESACTIVACIÓN

Modelo	Acc Exacta	Acc Tol (±1)	Macro F1	Prec	Rec	Pearson (*r*)	Spearman (*ρ*)
RoBERTuito Regresión	**48.40%**	**92.80%**	**0.4450**	**0.5008**	**0.4390**	**0.7326**	**0.7170**
RoBERTuito Multiclase	39.60%	84.00%	0.3900	0.4622	0.3793	0.5937	0.5825
RoBERTuito Base	20.00%	55.20%	0.1710	0.2536	0.1870	−0.0648	−0.0664
XLM-RoBERTa Large	12.40%	44.00%	0.1138	0.1962	0.1544	−0.0537	−0.0271

ACC TOLERANTE (±1) · REGRESIÓN

92,80%

Frente a 84,00% en Multiclase y 55,20% en Base

CONSISTENCIA DIRECCIONAL

r = 0,73 · ρ = 0,72

Relación fuerte que captura la tendencia afectiva

ACC EXACTA VS. AZAR (20%)

48,40%

Supera ampliamente el azar (XLM-R cae a 12,40%)

VENTAJA DE DOMINIO LINGÜÍSTICO

Tweets > Wiki

RoBERTuito Base supera a XLM-RoBERTa en coloquial

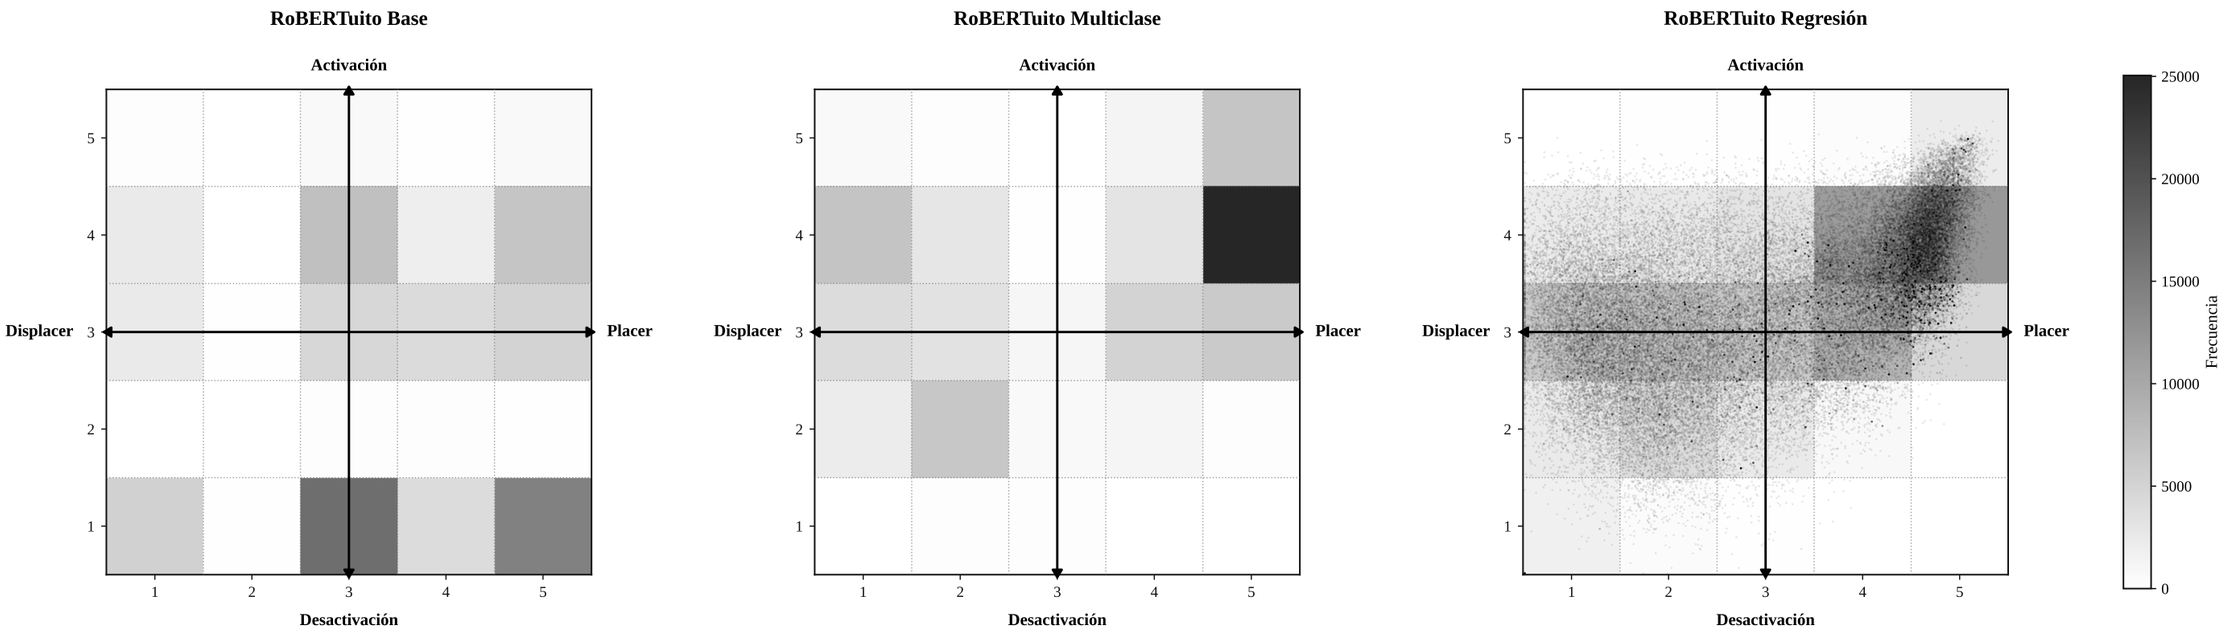
¿POR QUÉ ES MÁS COMPLEJA ESTA DIMENSIÓN EN PLN?

Mientras el placer/displacer tiene marcadores léxicos explícitos (elogios, insultos), la activación es contextual: un alto displacer puede expresarse con *alta activación* (ira, indignación) o con *fuerte desactivación* (tristeza, decepción, resignación).

PESO DEL CORPUS DE PREENTRENAMIENTO

En esta dimensión sutil, *RoBERTuito Base* (entrenado con tweets coloquiales en español) supera claramente a *XLM-RoBERTa Large* (entrenado en Wikipedia y noticias), que queda por debajo del azar estadístico (12,40%).

Ejemplos



1. ROBERTUITO BASE

Sin *fine-tuning* específico, no comprende el registro político local y distorsiona la distribución hacia el borde inferior.

2. ROBERTUITO MULTICLASE (SOFTMAX)

Captura la orientación general pero rigidiza el espacio afectivo en compartimentos estancos, perdiendo los matices intermedios.

3. ROBERTUITO REGRESIÓN (MSE)

Reconstruye la topografía continua del afecto nuclear, permitiendo medir grados de polarización afectiva y evitar inversiones polares.

Desempeño discriminativo por nivel (F1-Score):

TABLA 5. F1-SCORE POR NIVEL Y MACRO F1 · PLACER / DISPLACER

Modelo	Nivel 1	Nivel 2	Nivel 3	Nivel 4	Nivel 5	Macro F1
RoBERTuito Regresión	**0.75**	0.61	**0.53**	**0.52**	**0.86**	**0.6542**
RoBERTuito Multiclase	0.70	**0.62**	0.38	0.29	0.76	0.5505
XLM-RoBERTa Large	0.35	0.30	0.29	0.17	0.33	0.2872
RoBERTuito Base	0.37	0.32	0.00	0.10	0.37	0.2333

TABLA 6. F1-SCORE POR NIVEL Y MACRO F1 · ACTIVACIÓN / DESACTIVACIÓN

Modelo	Nivel 1	Nivel 2	Nivel 3	Nivel 4	Nivel 5	Macro F1
RoBERTuito Regresión	0.41	**0.45**	**0.57**	**0.49**	0.31	**0.4450**
RoBERTuito Multiclase	**0.43**	0.35	0.45	0.35	**0.37**	0.3900
RoBERTuito Base	0.20	0.13	0.19	0.27	0.06	0.1710
XLM-RoBERTa Large	0.04	0.18	0.05	0.16	0.13	0.1138

FORTALEZA DE LA REGRESIÓN (MSE) EN NIVELES INTERMEDIOS

Con idéntica arquitectura e hiperparámetros, la optimización por MSE supera holgadamente a Softmax en las posiciones moderadas e intermedias en ambas dimensiones.

COMPETENCIA MULTICLASE (SOFTMAX) EN LOS POLOS

En Activación/Desactivación, Multiclase conserva ventaja en el `Nivel 1` y `Nivel 5`. Softmax amplifica no linealmente las probabilidades ante marcadores léxicos extremos.

Al acotar predicciones en `[1.0, 5.0]` y penalizar desviaciones, la regresión dispone de solo **0,5 unidades** de margen en los extremos (1 y 5), frente al ancho completo de **1,0 unidad** en los niveles 2, 3 y 4.

Conclusiones:

FUNCIÓN DE PÉRDIDA

Regresión Ordinal (MSE) y Multiclase (Softmax)

Tratar el afecto nuclear como un continuo mediante MSE **evitó la inversión polar** (alcanzando **98,40%** y **92,80%** de exactitud tolerante) y capturó mejor los matices intermedios (niveles 2, 3 y 4).

Si solo interesara aislar polarización extrema (polos 1 y 5), *Multiclase* es competitivo; para modelar la totalidad del gradiente afectivo, la *Regresión Ordinal* es superior.

DIMENSIONES

Asimetría entre dimensiones

Placer / Displacer ofrece marcadores léxicos explícitos (insultos, elogios, términos partidarios) que facilitan la discriminación vectorial.

Activación / Desactivación es sutil y contextual: un fuerte displacer puede articularse desde la *alta activación* (ira, indignación) o desde la *baja activación* (tristeza, resignación), volviendo crítica la elección de la arquitectura y la función de pérdida.

FINE-TUNING

Preentrenamiento específico y adaptación local

`RoBERTuito Base` demostró un desempeño superior al interactuar con el registro coloquial de redes sociales en español frente a modelos multilingües generales.

A su vez, el **reentrenamiento (*fine-tuning*)** con una muestra anotada propia **duplicó las métricas de rendimiento**, superando las limitaciones de los modelos base ante la jerga propia del corpus.

// LIMITACIONES Y LÍNEAS FUTURAS

1. Arquitecturas ordinales: Contrastar esta formulación básica (neurona lineal + MSE) con arquitecturas específicas de la literatura de *ordinal learning*. | **2. Validación de anotación:** Implementar protocolos de anotación múltiple cruzada y métricas formales de acuerdo inter-jueces (*Kappa de Cohen* / *Alpha de Krippendorff*).

JORNADAS DE JÓVENES INVESTIGADORES · INSTITUTO DE INVESTIGACIONES GINO GERMANI

Muchas gracias

Agustín Nielsen (IIGG-FSOC-UBA)
Estudiante avanzado Lic. en Sociología (FSOC-UBA)

EJE 9 · TEORÍAS, EPISTEMOLOGÍAS Y METODOLOGÍAS
PLN · ANÁLISIS DE SENTIMIENTO · REGRESIÓN ORDINAL